Analyse Intelligente des Avis Clients

Outil generique de sentiment analysis multi-business

Projet de fin d'etudes -- Master 2 Expert Chef de Projet IA

Dataset final : 253,807 avis -- 5 entreprises -- 30 langues

Modele retenu : XLM-RoBERTa -- Accuracy 93.0% -- Macro F1 0.678

1. Contexte et objectif du projet

Contexte

Ce projet s'inscrit dans le dossier professionnel du Master 2 Expert Chef de Projet IA (EPSI). L'objectif est de construire un outil d'analyse intelligente des avis clients, capable de determiner automatiquement le sentiment (positif, negatif ou neutre) exprime dans un avis, quelle que soit la langue ou l'entreprise concernee.

Evolution du sujet

Le sujet portait initialement sur les avis de la neobanque Revolut. En cours de projet, le besoin a evolue vers un outil generaliste, utilisable pour n'importe quelle entreprise (e-commerce, transport, hotellerie...), sans avoir a re-entrainer un modele specifique a chaque fois.

Pourquoi le sentiment plutot que la note brute (1 a 5 etoiles) ?

La note brute souffre d'un desequilibre extreme (la grande majorite des avis sont a 5 etoiles) et les notes intermediaires (2 et 3 etoiles) sont trop rares pour qu'un modele apprenne a les reconnaitre correctement. Le sentiment (negatif/neutre/positif) est un concept plus universel, qui se transpose mieux d'un secteur a l'autre et qui est plus facile a apprendre correctement.

2. Collecte et preparation des donnees

Collecte des donnees

Aucun dataset Kaggle ne correspondait au besoin (avis multi-entreprises, multilingues). Les donnees ont donc ete collectees par scraping de sources publiques et legitimes :

- Google Play Store (avis d'applications mobiles, 15 langues cibles)
- Apple App Store (flux RSS public des avis)

5 entreprises ont ete scrapees pour obtenir un dataset varie : Revolut (banque), Amazon (e-commerce), Uber (transport), Uber Eats (livraison de repas), Booking.com (hotellerie).

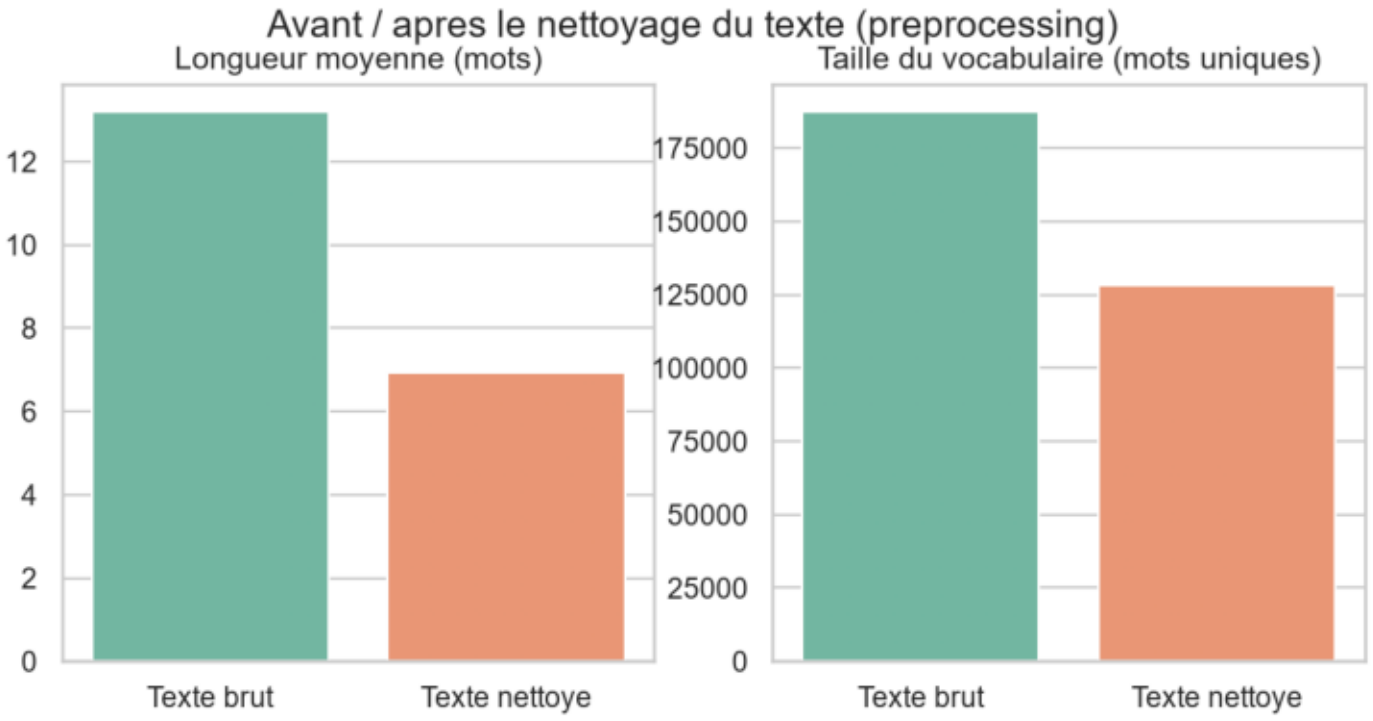
Pourquoi plusieurs secteurs ? Pour qu'un seul modele apprenne des schemas de sentiment generaux (mots positifs/negatifs, tournures de phrase) plutot que des particularites propres a une seule entreprise -- condition necessaire pour qu'il generalise a une entreprise qu'il n'a jamais vue.

Nettoyage des donnees (niveau document)

- Suppression des avis vides ou strictement dupliques
- Filtrage des avis non rediges en alphabet latin
- Detection de la langue (au-dela de 20 caracteres, sinon trop peu fiable)

Resultat : un dataset final de 253,807 avis, repartis sur 5 entreprises et 30 langues. Le detail du nettoyage du TEXTE (mots vides, lemmatisation) est presente page suivante, avec la comparaison avant/apres.

3. Avant / apres le nettoyage du texte

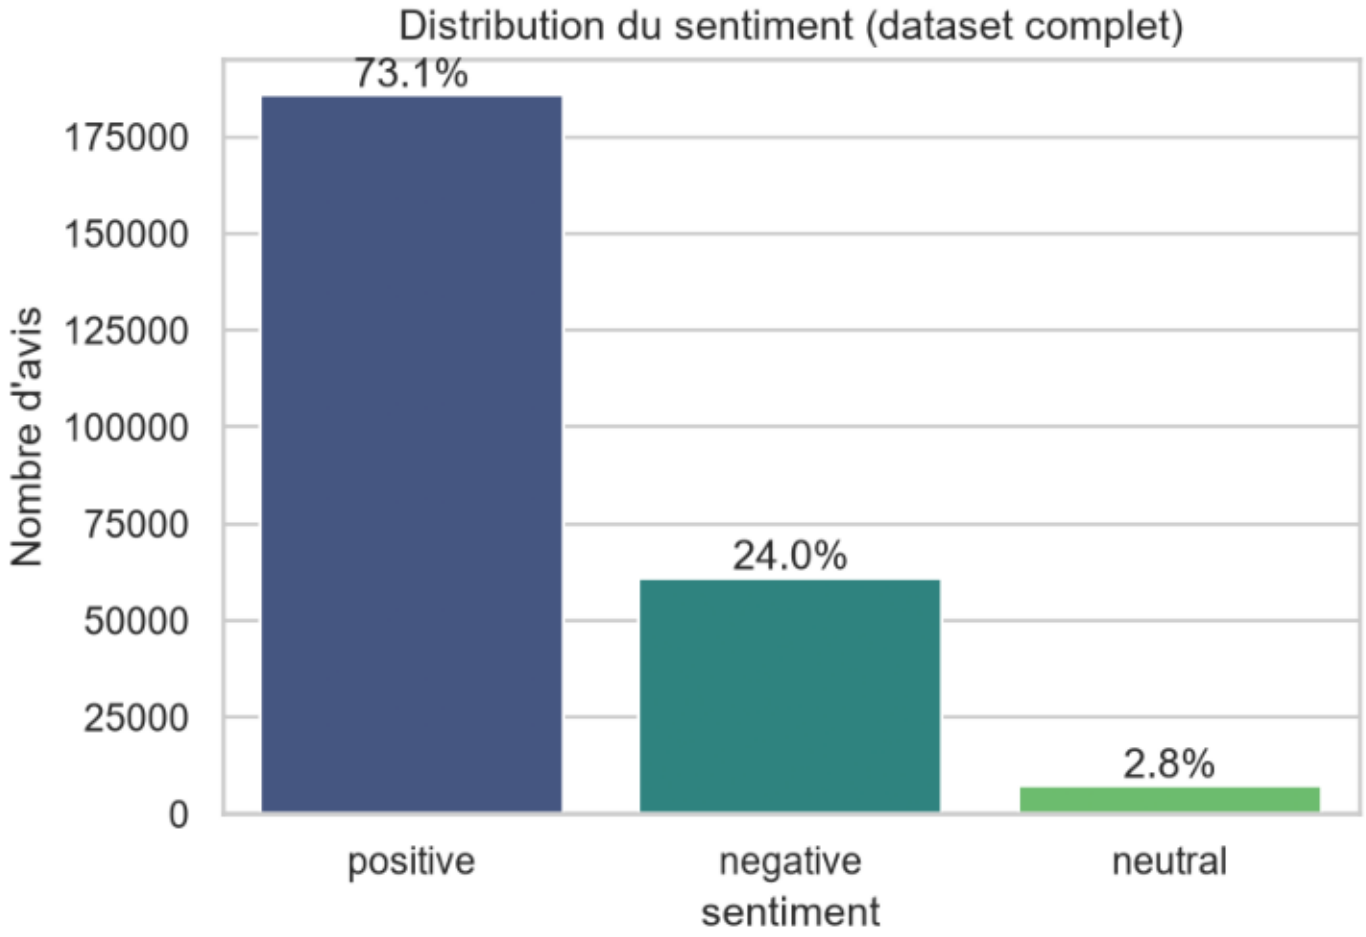


Comment lire ce graphique : a gauche, la longueur moyenne d'un avis (en mots) avant et apres nettoyage. A droite, le nombre de mots uniques (vocabulaire) avant et apres.

Ce que ca montre : le texte brut fait 13.2 mots en moyenne, contre 6.9 apres suppression des mots vides et lemmatisation -- une reduction attendue, le but etant de ne garder que les mots porteurs de sens. Le vocabulaire passe de 187,332 a 128,309 mots uniques : la lemmatisation regroupe les variantes d'un meme mot (jouait/jouer) sous une seule forme, ce qui reduit la dimensionnalite traitee par les modeles classiques (TF-IDF).

Important : ce nettoyage ne s'applique qu'a la copie de texte utilisee par les modeles classiques. Le Transformer (XLM-RoBERTa) utilise le texte BRUT, non nettoye, car il a besoin de la ponctuation et des mots vides pour comprendre le contexte complet de la phrase.

4. Repartition du sentiment dans le dataset

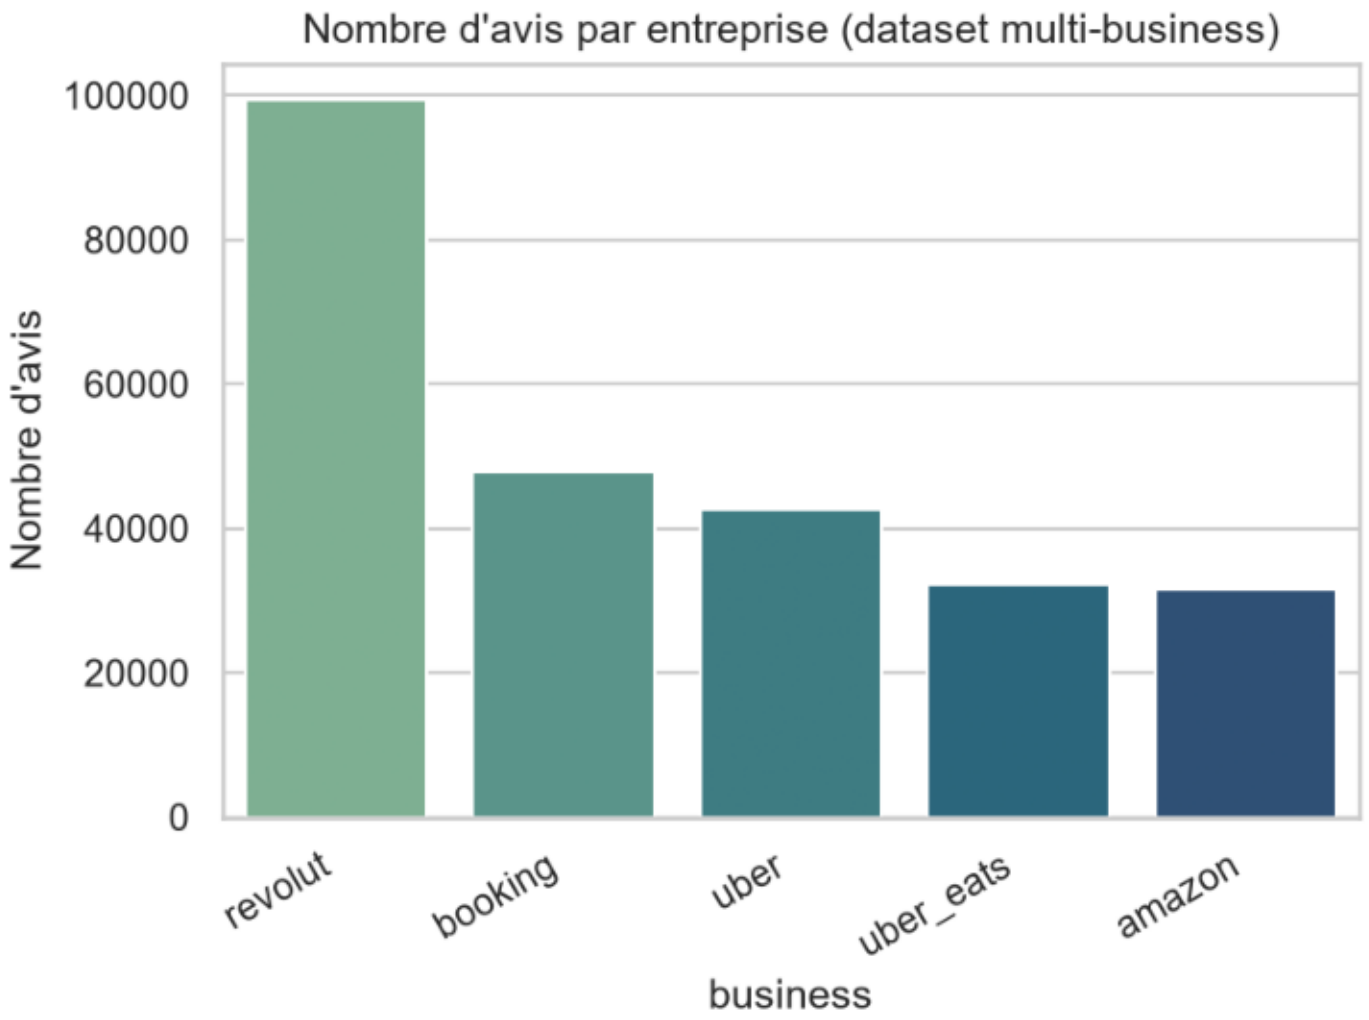


Comment lire ce graphique : chaque barre represente le nombre d'avis pour chaque categorie de sentiment, avec le pourcentage du total au-dessus.

Ce que ca montre : le dataset est desequilibre -- 73% des avis sont positifs, 24% negatifs, et seulement 3% neutres.
Ce desequilibre est une caracteristique naturelle des avis clients reels : les clients laissent plus souvent un avis quand ils sont tres satisfaits ou tres mecontents, rarement quand leur experience est simplement 'moyenne'.

Impact sur la modelisation : ce desequilibre oblige a utiliser des metriques adaptees (macro F1 plutot que l'accuracy seule) et explique pourquoi la categorie 'neutre' reste la plus difficile a predire pour tous les modeles.

5. Volume d'avis par entreprise

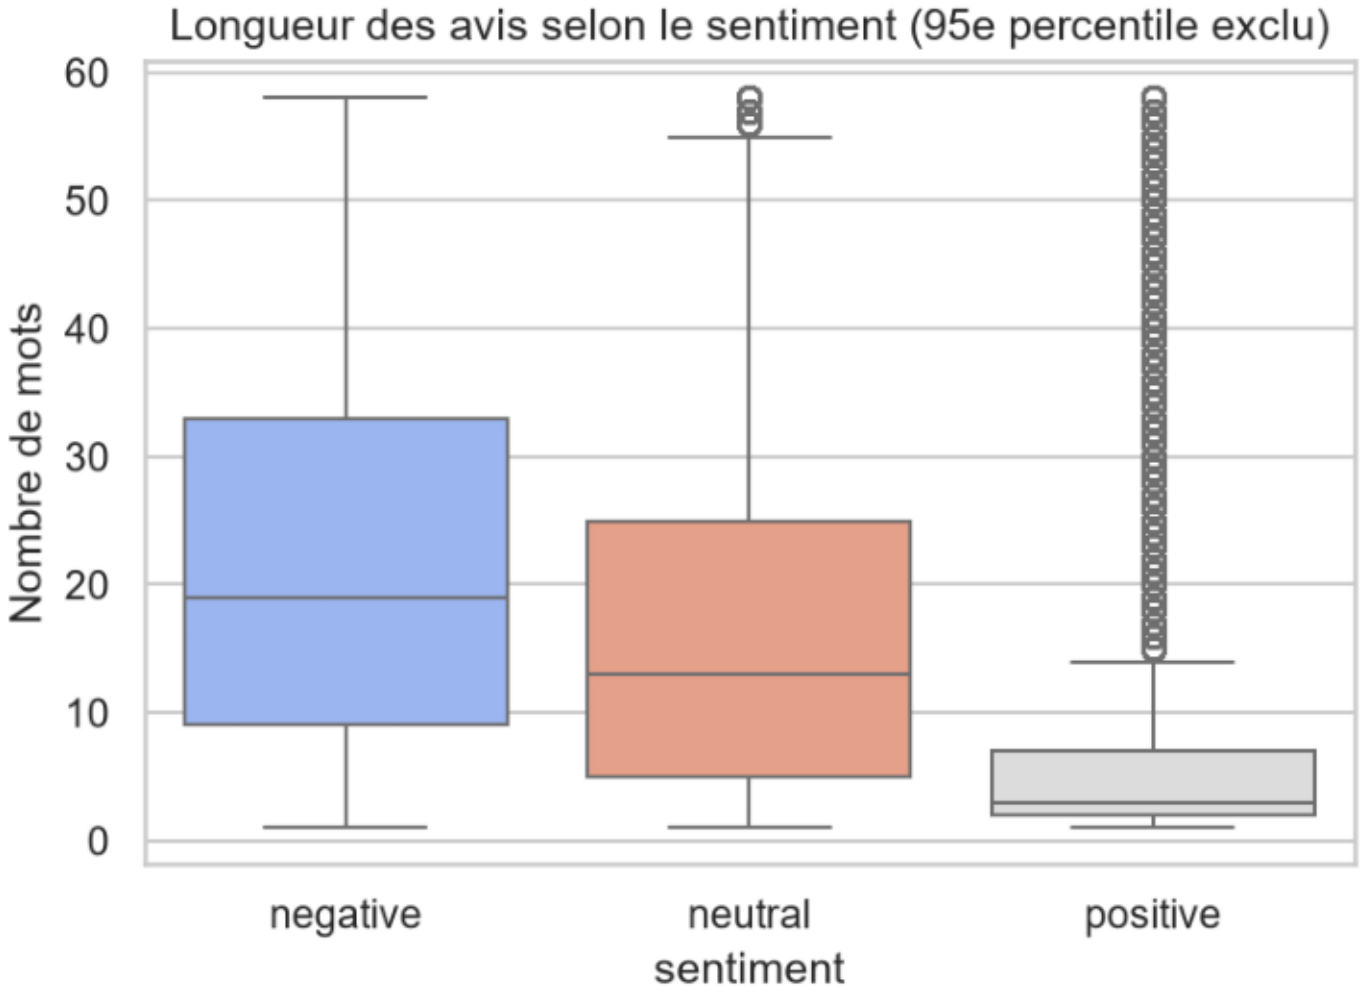


Comment lire ce graphique : nombre total d'avis collectes pour chacune des 5 entreprises du dataset.

Ce que ca montre : le volume est globalement equilibre entre les entreprises, ce qui garantit qu'aucune entreprise ne domine excessivement l'apprentissage.

Pourquoi c'est important : un modele entraine sur un seul secteur risquerait d'apprendre des mots-cles trop specifiques ("virement", "carte bloquee") qui ne se retrouvent pas dans d'autres secteurs ("livraison en retard", "chambre sale"). Melanger les secteurs force le modele a apprendre des indices de sentiment plus generaux, donc plus transferables.

6. Longueur des avis selon le sentiment



Comment lire ce graphique (boite a moustaches / boxplot) : pour chaque sentiment, la boite represente ou se situent 50% des avis (entre le 1er et le 3e quartile), le trait au milieu est la mediane, et les moustaches montrent l'etendue des valeurs courantes.

Ce que ca montre : les avis negatifs sont generalement plus longs que les avis positifs. Hypothese habituelle en analyse d'avis clients : les clients mecontents prennent plus de temps a detailler ce qui n'a pas fonctionne, alors qu'un avis positif se resume souvent a une phrase courte ('super !').

Interet pour le modele : la longueur n'est pas utilisee comme variable explicite, mais elle confirme que les avis negatifs contiennent plus d'information textuelle exploitable par les modeles.

7. Mots les plus frequents par sentiment

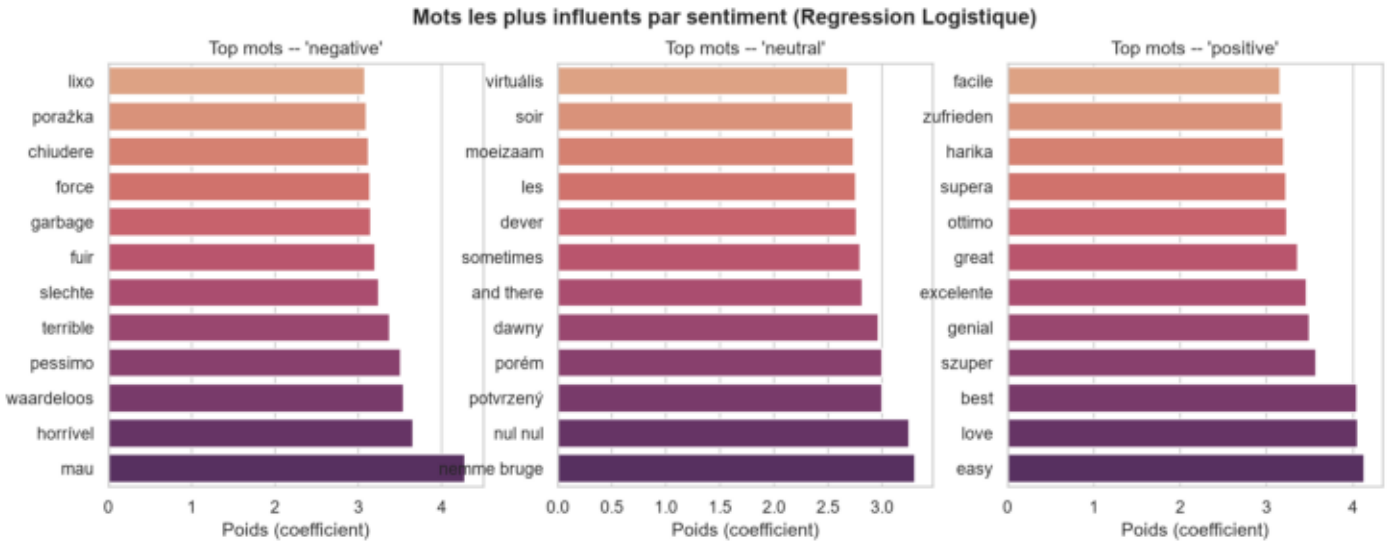


Comment lire ce graphique : plus un mot est gros, plus il apparait souvent dans les avis de cette categorie (apres nettoyage : mots vides retires, lemmatises).

Ce que ca montre : les noms des entreprises et des applications ('uber', 'amazon', 'booking', 'app'...) dominent dans les 3 categories, car ils sont frequents partout, peu importe le sentiment. C'est une limite connue du nuage de mots, qui se base sur la frequence brute plutot que sur le caractere distinctif d'un mot.

C'est justement pourquoi la page suivante (feature importance) est plus utile pour l'analyse : elle met en avant les mots qui distinguent vraiment un sentiment d'un autre, et non les mots simplement frequents.

8. Mots les plus influents par sentiment (interpretabilite)



Comment lire ce graphique : pour le modele de Regression Logistique, chaque mot du vocabulaire a un poids (coefficient) par categorie. Plus le poids est eleve, plus la presence de ce mot pousse le modele a predire cette categorie. Les 12 mots les plus influents sont affiches pour chaque sentiment.

Ce que ca montre : on retrouve des mots de sentiment attendus, ce qui valide que le modele apprend des signaux pertinents plutot que des correlations fortuites. C'est un premier niveau d'interpretabilite (feature importance), moins fin qu'une analyse SHAP/LIME par avis individuel, mais qui permet deja de verifier que le modele 'raisonne' sur des bases sensees.

9. Methodologie de modelisation

5 modeles ont ete entraines et compares sur les memes donnees (memes ensembles d'entrainement / validation / test, repartition 70%/15%/15%), pour garantir une comparaison equitable.

Approche 1 : Machine Learning classique (TF-IDF)

Le texte est transforme en vecteurs numeriques representant l'importance de chaque mot (TF-IDF), puis un classifieur apprend a separer les categories. 4 classifieurs ont ete testes sur les memes vecteurs :

- Naive Bayes : modele probabiliste simple et rapide (base historique du filtrage de spam)
- Random Forest : ensemble d'arbres de decision
- Regression Logistique : modele lineaire, robuste sur des donnees a tres haute dimension
- SVM lineaire : cherche la meilleure frontiere de separation entre les categories

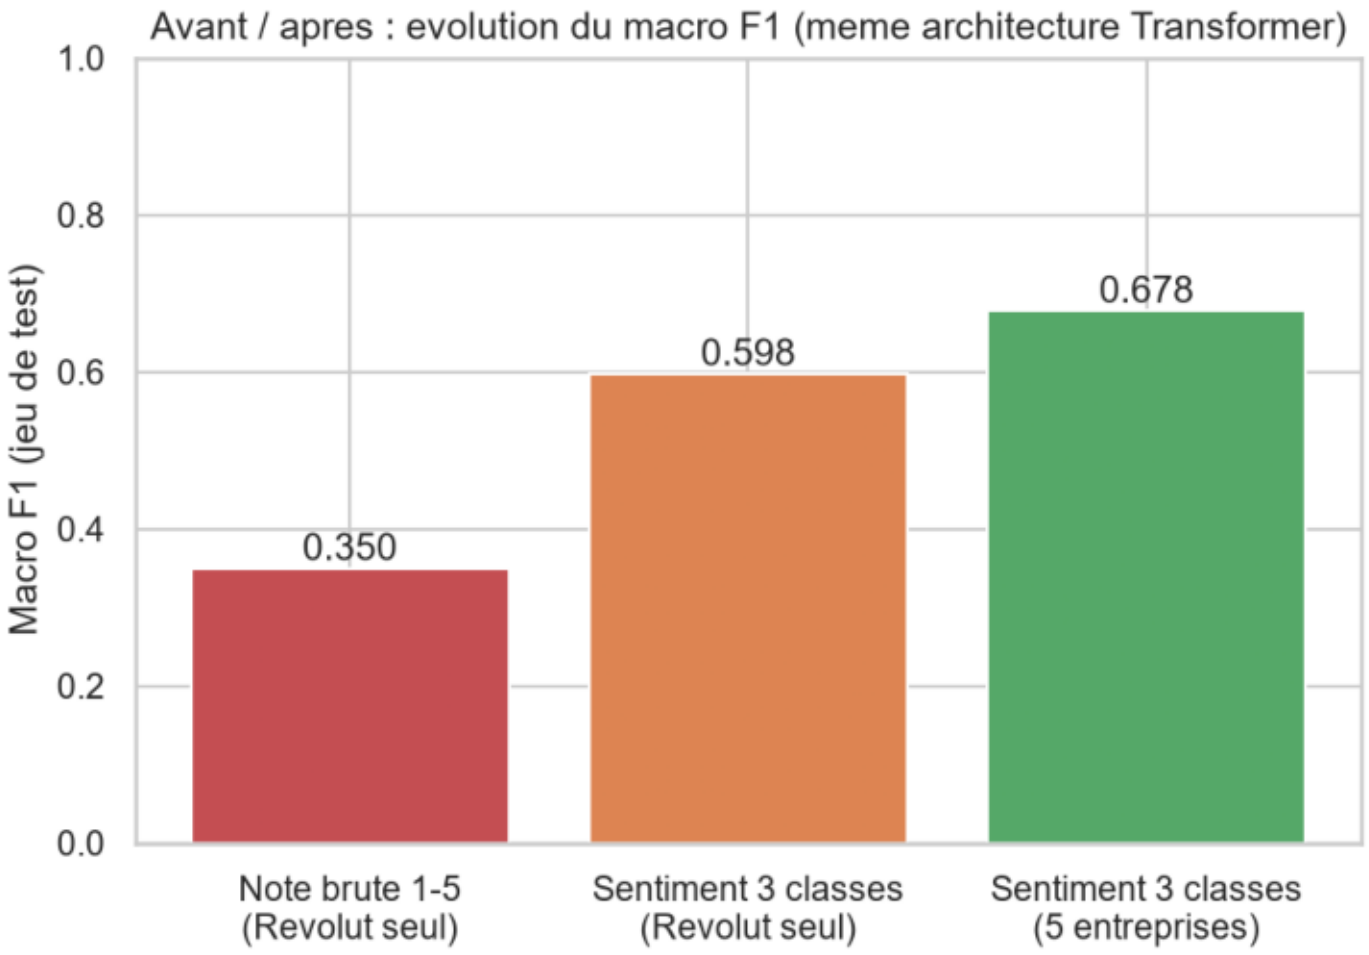
Approche 2 : Deep Learning (Transformer)

XLM-RoBERTa, un modele pre-entraine sur d'enormes corpus multilingues, puis affine (fine-tuning) sur nos donnees. Contrairement au TF-IDF qui traite le texte comme un simple 'sac de mots', le Transformer comprend l'ordre des mots et le contexte (ex: distinguer 'pas mauvais' de 'mauvais').

Pourquoi XLM-RoBERTa et pas CamemBERT/RoBERTa (prevus initialement) : ces deux modeles sont monolingues (francais / anglais uniquement), incompatibles avec un dataset en 15+ langues. XLM-RoBERTa est l'equivalent multilingue de cette famille de modeles.

Gestion du desequilibre : chaque modele utilise une ponderation des classes pour eviter qu'il ignore les categories minoritaires (class_weight='balanced' pour les modeles classiques, ponderation de la fonction de perte pour le Transformer).

10. Avant / apres : amelioration du modele (post-traitement)

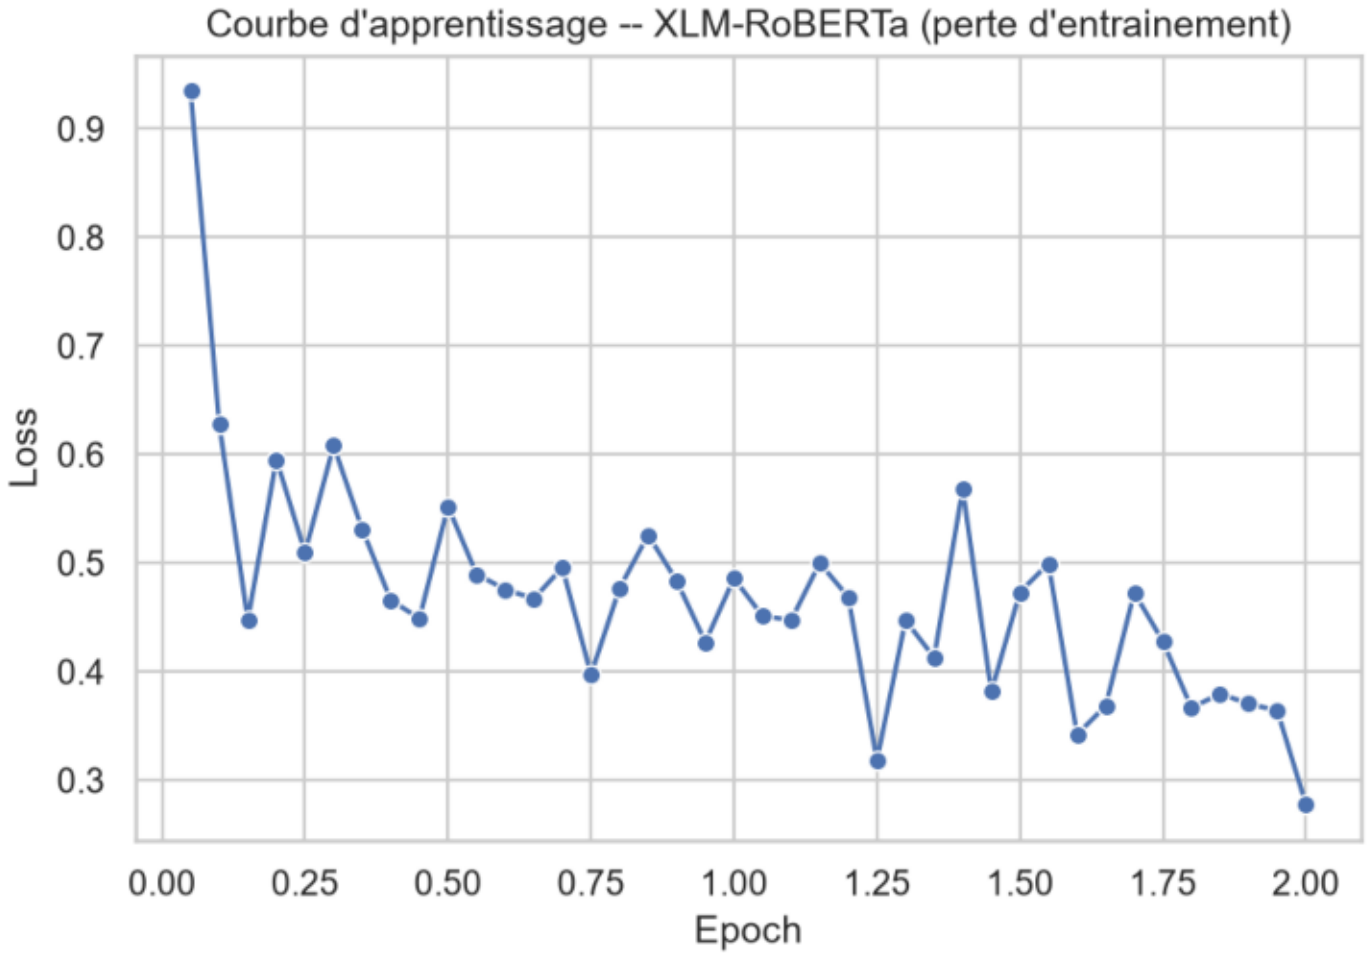


Comment lire ce graphique : evolution du macro F1 du MEME modele (architecture Transformer XLM-RoBERTa) au fil de 3 ameliorations successives du dataset et de la cible, sans changer l'architecture elle-meme.

Etape 1 (rouge) : modele entraine sur la note brute 1-5, sur Revolut seul.
Etape 2 (orange) : la cible est changee pour le sentiment (3 classes), encore sur Revolut seul -- gain important car les classes 2/3 etoiles, trop rares, ne pouvaient pas etre apprises individuellement.
Etape 3 (vert) : le dataset est etendu a 5 entreprises -- gain supplementaire car le modele dispose de plus d'exemples, notamment pour la classe la plus rare ('neutre').

Conclusion : chaque amelioration a ete mesuree avant d'etre adoptee -- aucun choix n'a ete fait par hypothese seule.

11. Courbe d'apprentissage du modele final

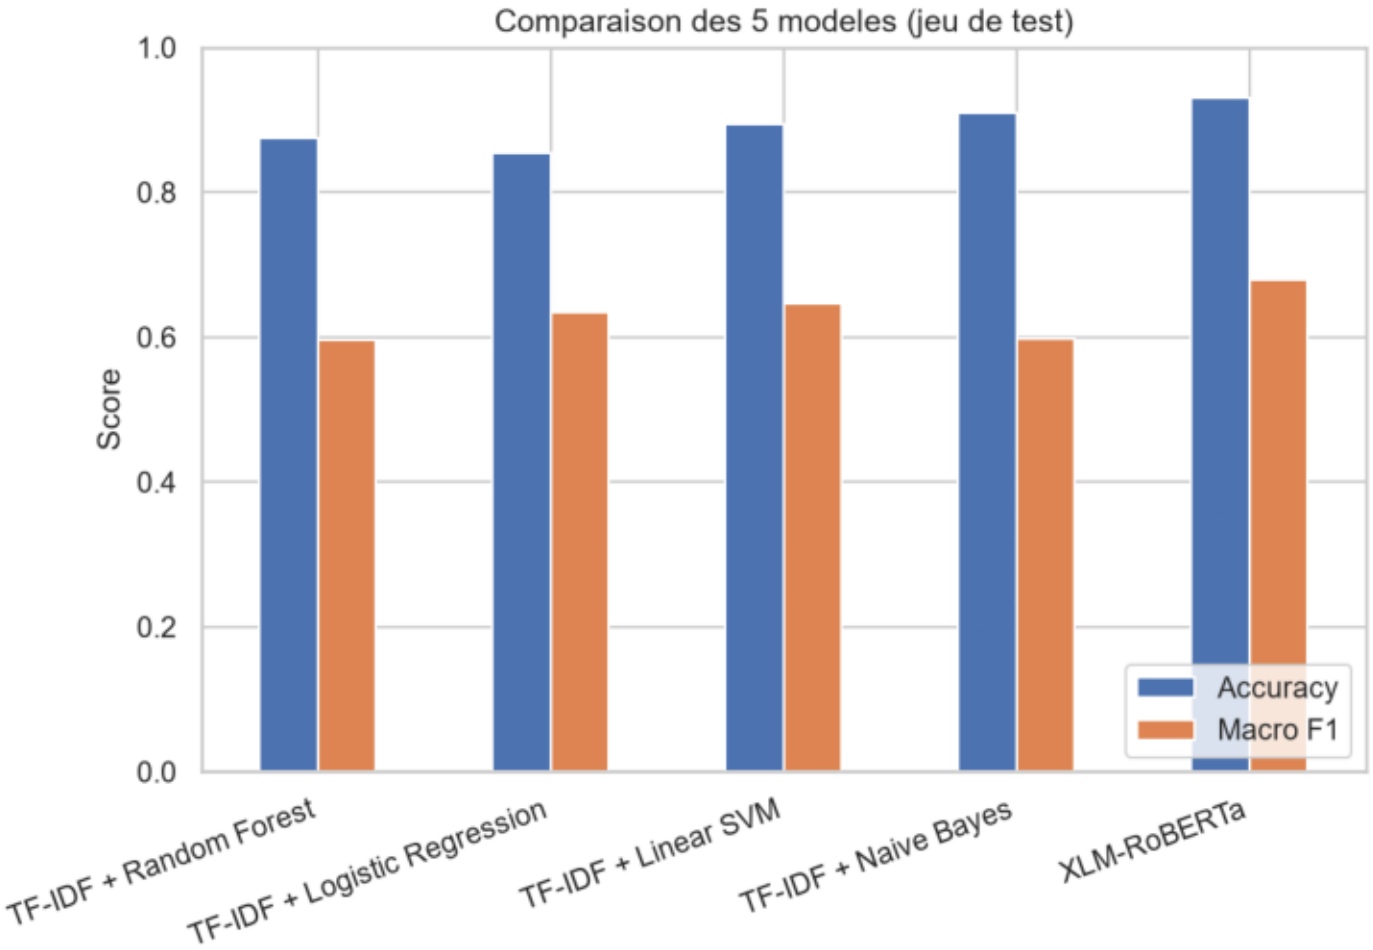


Comment lire ce graphique : la 'loss' (perte) mesure a quel point les predictions du modele s'eloignent des vraies reponses pendant l'entrainement. Plus elle baisse, mieux le modele apprend.

Ce que ca montre : la perte diminue de facon reguliere au fil des epochs, sans repartir a la hausse ni stagner brutalement -- signe d'un entrainement stable, sans surapprentissage flagrant a ce stade.

Contexte : un essai precedent avec une ponderation de classe trop forte avait produit une perte qui ne baissait pas du tout (modele bloque) -- ce graphique permet de verifier visuellement que ce probleme est resolu.

12. Comparaison des 5 modeles entraines



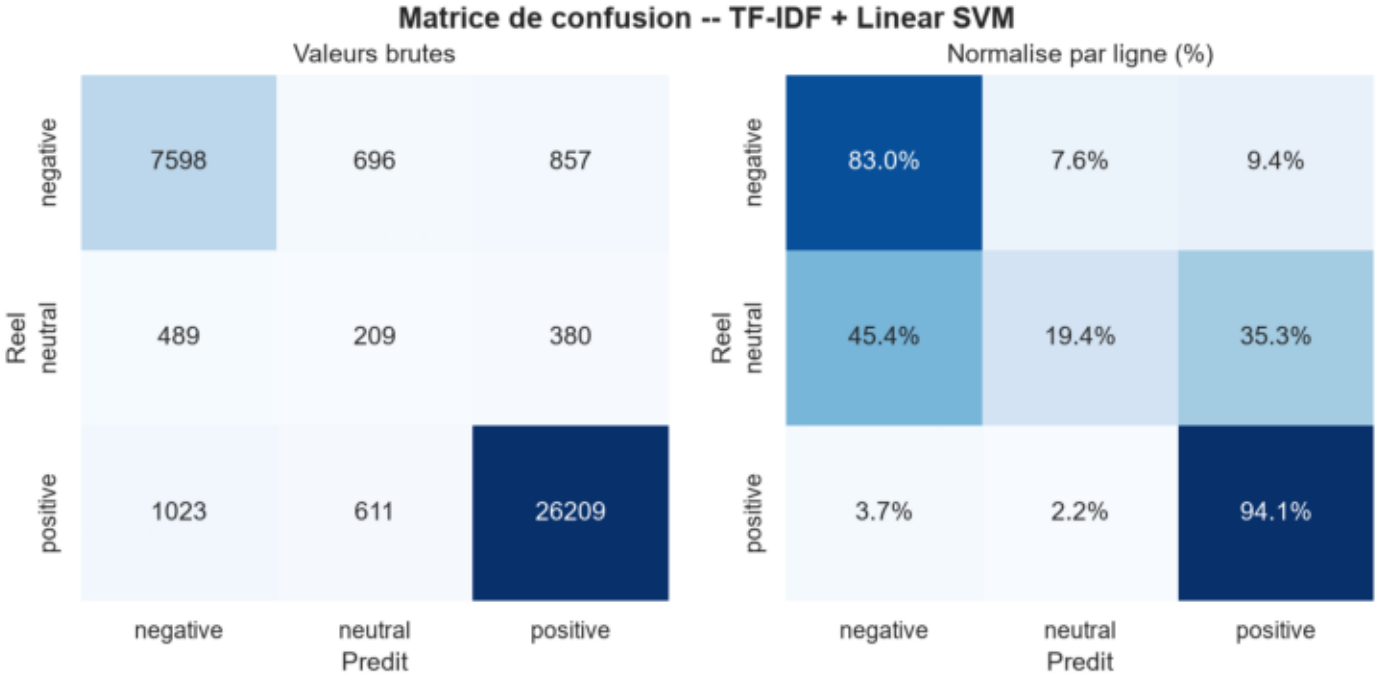
Comment lire ce graphique : pour chaque modele, deux scores sont affiches :
l'accuracy (% de predictions correctes, en bleu) et le macro F1 (en orange).

Pourquoi deux metriques differentes : l'accuracy seule serait trompeuse ici.
Un modele qui predit systematiquement 'positif' obtiendrait une accuracy
d'environ 73% sans rien avoir appris -- juste parce que 73% des avis sont
reellement positifs. Le macro F1 calcule un score pour chaque categorie
separement puis fait la moyenne des 3, sans favoriser la categorie
majoritaire. C'est la metrique de reference retenue pour choisir le modele.

Resultats detailles (jeu de test) :

TF-IDF + Random Forest	accuracy=0.875	macro F1=0.595
TF-IDF + Logistic Regression	accuracy=0.855	macro F1=0.635
TF-IDF + Linear SVM	accuracy=0.893	macro F1=0.647
TF-IDF + Naive Bayes	accuracy=0.910	macro F1=0.598
XLM-RoBERTa	accuracy=0.930	macro F1=0.678

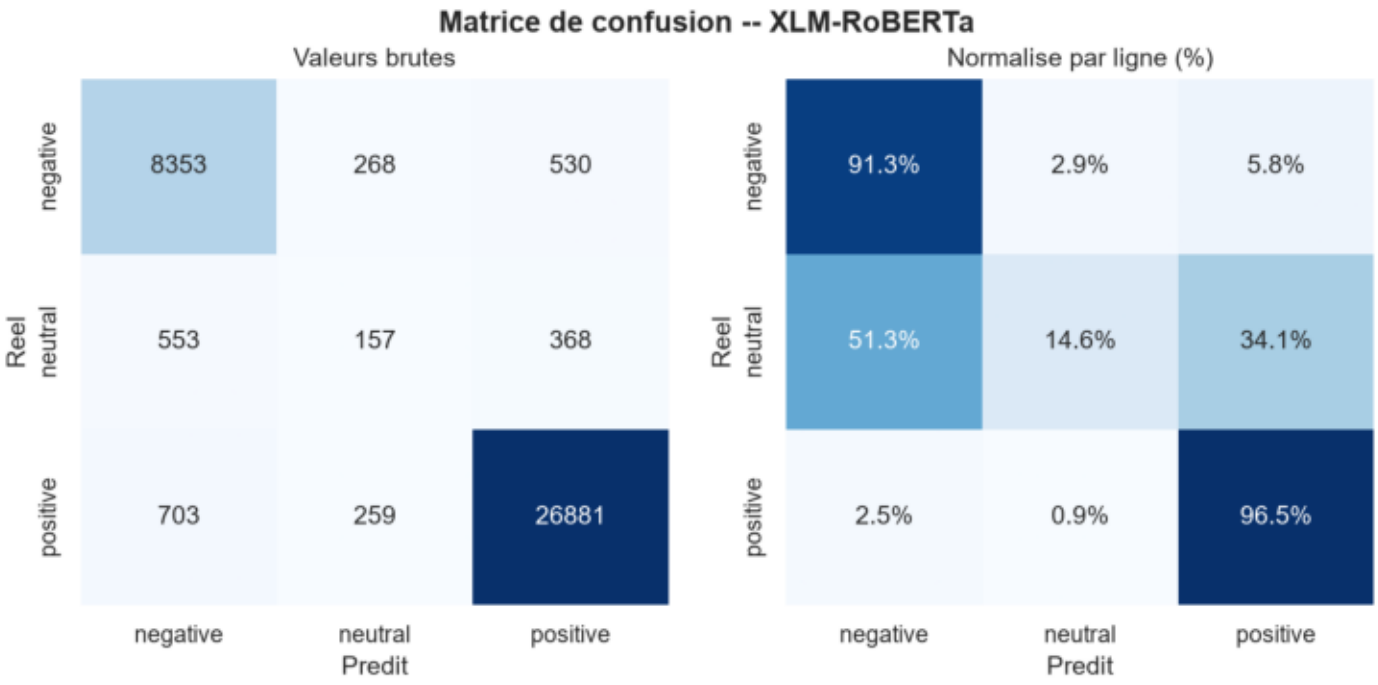
13. Matrice de confusion -- meilleur modele classique



Comment lire une matrice de confusion : chaque LIGNE correspond au sentiment REEL de l'avis, chaque COLONNE au sentiment PREDIT. La diagonale represente les predictions correctes. A gauche, les valeurs brutes (nombre d'avis) ; a droite, les memes valeurs normalisees en % PAR LIGNE -- utile ici car la classe 'neutre' a si peu d'avis que ses erreurs sont invisibles en valeurs brutes a cote des dizaines de milliers d'avis positifs.

Lecture pour le SVM lineaire : 'negatif' et 'positif' sont bien separes. La vue en % revele que la grande majorite des avis 'neutres' sont mal classes, repartis a peu pres entre 'negatif' et 'positif'.

14. Matrice de confusion -- modele retenu (XLM-RoBERTa)



Meme principe de lecture que la page precedente (lignes = reel, colonnes = predit, diagonale = bonnes predictions, vue de droite normalisee en %).

Lecture pour XLM-RoBERTa : 'negatif' et 'positif' sont tres bien separes, avec une concentration encore plus forte sur la diagonale que le modele classique (visible dans la vue en % : pourcentages plus proches de 100%). La vue en % montre aussi que le modele identifie desormais une part non negligeable d'avis 'neutres' -- une amelioration reelle, meme si la marge de progression reste la plus importante sur cette categorie.

15. Choix final et justification

Modele retenu pour la production : XLM-RoBERTa

Justification :
1. Meilleur score sur la metrique de reference (macro F1 = 0.678, soit +0.031 par rapport au meilleur modele classique)
2. Seul modele a comprendre le contexte et l'ordre des mots (negations, nuances), contrairement aux modeles TF-IDF qui traitent le texte comme un sac de mots
3. Pre-entraine sur des corpus multilingues massifs : il 'connait' deja les 15+ langues avant meme d'etre affine sur nos donnees

Limite assumee : le temps d'entrainement et d'inference est plus eleve qu'un modele classique. Sans GPU disponible, l'entrainement a ete limite a un sous-echantillon de 16 000 avis (sur 178 000 disponibles), pour rester dans un budget de calcul raisonnable sur CPU (environ 1h10 d'entrainement).

Avantages et limites de chaque approche

TF-IDF + ML classique :
+ Rapide a entrainer (quelques secondes a minutes)
+ Facile a interpreter (on peut voir quels mots pesent dans la decision)
- Ne capture pas le contexte ni l'ordre des mots

Transformer (XLM-RoBERTa) :
+ Capture le contexte et la nuance
+ Meilleure performance globale
- Plus lent a entrainer et plus gourmand en ressources de calcul

16. Mise a disposition du modele

Une API (FastAPI) expose le modele retenu via deux endpoints :

- POST /predict : analyse un avis unique, renvoie le sentiment et le niveau de confiance
- POST /predict/batch : analyse jusqu'a 500 avis en une fois, avec un score global agrege -- concu pour le cas d'usage 'une entreprise fournit son dataset d'avis et veut un verdict d'ensemble'

Un tableau de bord (Streamlit) permet de tester le modele sans ecrire de code, avec 4 onglets :

- Prediction en direct : sur un avis saisi a la main
- Analyse d'un dataset : upload d'un fichier CSV, score global + repartition positif/negatif/neutre, telechargement des resultats
- Statistiques du dataset : volumes, langues, sentiment, par entreprise
- Performance des modeles : comparaison visuelle des 5 modeles entraines

17. Etat d'avancement et perspectives

Termine

- Exploration et preparation des donnees (multi-source, multi-business, multilingue)
- Preprocessing NLP adapte a chaque famille de modele, avec comparaison avant/apres
- Modelisation : 5 modeles entraines, evalues et compares
- Amelioration mesuree du dataset/de la cible (avant/apres post-traitement)
- Backend (API FastAPI) et Frontend (Dashboard Streamlit)

A venir

- Conteneurisation Docker et pipeline CI/CD (GitHub Actions)
- Discussion approfondie biais/variance et surapprentissage par modele
- Interpretabilite avancee (SHAP/LIME) pour expliquer les predictions individuelles (au-dela de la feature importance globale deja presentee)

Conclusion

Le projet demontre une chaine complete, de la collecte de donnees brutes jusqu'a un outil utilisable (API + dashboard), avec une demarche methodique : chaque choix (cible du modele, perimetre des donnees, type de modele) a ete pris puis valide par une mesure chiffree, et non par simple hypothese.